

Année universitaire 2025–2026

BUT Science des Données

SAE – Régression sur données réelles

Étude des courbes de croissance

Guinée-Bissau & Papouasie Nouvelle-Guinée

SAE « Régression – Projet 35 »

Auteurs: William Houblon-Tchagam, Florent Danlos, Nathan Sokol

Étude internationale 2020 | Enfants âgés de 5 à 19 ans

1	Introduction	1
2	Analyse descriptive	1
2.1	Chargement des données et constitution des sous-groupes.....	1
2.2	Présentation des données	1
2.3	Statistiques descriptives de la taille	2
2.4	Distribution par boîtes à moustaches.....	3
3	Corrélation et modèle linéaire	4
4	Ajustement polynomial	5
4.1	Méthode	5
4.2	Résultats de la sélection par AIC.....	6
4.2.1	Filles – Guinée-Bissau (GBG).....	6
4.2.2	Garçons – Guinée-Bissau (GBB)	6
4.2.3	Filles – Papouasie Nouvelle-Guinée (PNGG).....	7
4.2.4	Garçons – Papouasie Nouvelle-Guinée (PNGB)	7
4.2.5	Tableau récapitulatif des AIC	8
4.3	Courbes d’ajustement polynomiales	9
5	Courbes médianes et quartiles conditionnels	11
5.1	Méthode	11
5.2	Résultats.....	11
6	Comparaisons et conclusions	14
6.1	Comparaison filles / garçons	14
6.2	Comparaison des deux pays	15
6.3	Tests statistiques Taille ~ Sexe et Pays	17
6.4	Qualité des modèles.....	18
7	Conclusion	18
8	Summary	19

1 Introduction

Dans le cadre d'une étude internationale conduite en 2020 dans plus de 90 pays, des données anthropométriques ont été collectées auprès d'enfants et d'adolescents âgés de 5 à 19 ans. Pour chaque pays, 200 médecins (généralistes ou pédiatres) ont été tirés au sort sur l'ensemble du territoire national. Chaque praticien a ensuite sélectionné aléatoirement 20 patients (10 filles et 10 garçons) dans cette tranche d'âge, et a enregistré leur âge (en années décimales, arrondi à un chiffre après la virgule) ainsi que leur taille (en centimètres, arrondie de même).

Ainsi, pour chaque pays, un échantillon de 4 000 enfants est disponible, réparti équitablement entre les deux sexes. Le présent rapport porte sur deux pays de l'étude : la **Guinée-Bissau (GB)**, pays d'Afrique de l'Ouest, et la **Papouasie Nouvelle-Guinée (PNG)**, pays d'Océanie. Ces deux pays présentent des contextes géographiques, nutritionnels et sanitaires très différents, ce qui rend leur comparaison particulièrement intéressante sur le plan statistique.

L'objectif de cette étude est triple :

1. Analyser descriptivement les distributions de la taille et de l'âge pour chaque sous-groupe ;
2. Ajuster des modèles de régression polynomiale pour modéliser la relation taille-âge ;
3. Visualiser les courbes médianes et les courbes des quartiles conditionnels, qui constituent des outils standards en épidémiologie de la croissance.

2 Analyse descriptive

2.1 Chargement des données et constitution des sous-groupes

```
# Chargement des données
load("Data_Projet35.RData")
library(dplyr)

# Constitution des sous-groupes par pays
GB <- Data[Data$Pays == "Guinea Bissau", ]
PNG <- Data[Data$Pays == "Papua New Guinea", ]

# Sous-groupes par sexe
GBB <- GB[GB$Sexe == "Boys", ]
GBG <- GB[GB$Sexe == "Girls", ]
PNGB <- PNG[PNG$Sexe == "Boys", ]
PNGG <- PNG[PNG$Sexe == "Girls", ]
```

2.2 Présentation des données

Les données se composent de **8 000 observations** au total (4 000 par pays, 2 000 par groupe sexe $\times$ pays). Les variables disponibles sont : Pays (Guinée-Bissau ou Papouasie Nouvelle-Guinée),

Sexe (Girls/Boys), Age (années décimales, 5 à 19 ans) et Taille (centimètres). La répartition est parfaitement équilibrée par pays et par sexe, ce qui est une conséquence directe du protocole de collecte.

```
head(Data)
```

```
## # A tibble: 6 x 4
##   Pays      Sexe   Age  Taille
##   <fct>    <fct> <dbl> <dbl>
## 1 Guinea Bissau Boys  18.5   170.
## 2 Guinea Bissau Boys  11.0   139.
## 3 Guinea Bissau Boys  18.6   163.
## 4 Guinea Bissau Boys   7.81  119.
## 5 Guinea Bissau Boys   9.88  131.
## 6 Guinea Bissau Boys   5.84  108.
```

2.3 Statistiques descriptives de la taille

```
# Statistiques descriptives de la taille par groupe
groupes <- list(
  "GBG (Filles GB)" = GBG$Taille,
  "GBB (Garçons GB)" = GBB$Taille,
  "PNGG (Filles PNG)" = PNGG$Taille,
  "PNGB (Garçons PNG)" = PNGB$Taille
)

stats_table <- data.frame(
  Groupe      = names(groupes),
  Taille_moy  = sapply(groupes, mean) |> round(1),
  Ecart_type  = sapply(groupes, sd)   |> round(1),
  Min         = sapply(groupes, min)  |> round(1),
  Max         = sapply(groupes, max)  |> round(1)
)

knitr::kable(
  stats_table,
  col.names = c("Groupe", "Taille moy. (cm)", "Écart-type", "Min (cm)", "Max (cm)"),
  caption   = "Statistiques descriptives de la taille par groupe",
  align     = "lcccc",
  booktabs = TRUE
)
```

TABLE 1: Statistiques descriptives de la taille par groupe

Groupe	Taille moy. (cm)	Écart-type	Min (cm)	Max(cm)
GBG (Filles GB)	142.3	16.4	105.7	166.8
GBB (Garçons GB)	142.4	20.0	101.5	177.4
PNGG (Filles PNG)	139.6	16.2	103.8	165.4
PNGB (Garçons PNG)	139.2	20.2	98.3	173.0

On observe que les tailles moyennes sont très proches entre filles et garçons à l'intérieur d'un même pays. Cependant, les garçons présentent systématiquement un écart-type plus élevé (≈ 20 cm contre ≈ 16 cm pour les filles), reflétant une variabilité plus importante notamment liée à la puberté tardive chez les garçons. Les enfants de Guinée-Bissau sont légèrement plus grands en moyenne que ceux de Papouasie Nouvelle-Guinée, toutes choses égales par ailleurs.

2.4 Distribution par boîtes à moustaches

```
par(mfrow = c(1, 2))

# Boxplot des âges
boxplot(
  GBG$Age, GBB$Age, PNGG$Age, PNGB$Age,
  names = c("GB\nFilles", "GB\nGarçons", "PNG\nFilles", "PNG\nGarçons"),
  col    = c("pink", "lightblue", "pink", "lightblue"),
  main   = "Distribution de l'Âge",
  ylab   = "Âge (années)"
)

# Boxplot des tailles
boxplot(
  GBG$Taille, GBB$Taille, PNGG$Taille, PNGB$Taille,
  names = c("GB\nFilles", "GB\nGarçons", "PNG\nFilles", "PNG\nGarçons"),
  col    = c("pink", "lightblue", "pink", "lightblue"),
  main   = "Distribution de la Taille",
  ylab   = "Taille (cm)"
)
```




FIGURE 1 – Distributions de l'âge et de la taille par groupe (boîtes à moustaches)

```
par(mfrow = c(1, 1))
```

Les distributions d'âge sont très homogènes entre les quatre groupes, confirmant le bon équilibre de l'échantillonnage. Pour la taille, on constate que les distributions sont assez symétriques, avec une légère asymétrie positive pour les garçons (valeurs maximales plus éloignées). Les médianes de taille sont similaires pour les deux pays, mais la dispersion interquartile est plus large chez les garçons, conformément aux observations précédentes.

3 Corrélation et modèle linéaire

Avant d'aborder la régression polynomiale, il convient d'examiner la relation linéaire entre l'âge et la taille.

```
# Calcul des corrélations de Pearson par groupe
cor_GBG <- cor(GBG$Age, GBG$Taille)
cor_GBB <- cor(GBB$Age, GBB$Taille)
cor_PNGG <- cor(PNGG$Age, PNGG$Taille)
cor_PNGB <- cor(PNGB$Age, PNGB$Taille)

cor_table <- data.frame(
  Groupe = c("GBG (Filles Guinée-Bissau)", "GBB (Garçons Guinée-Bissau)",
             "PNGG (Filles Papouasie N.-G.)", "PNGB (Garçons Papouasie N.-G.)"),
  r       = c(cor_GBG, cor_GBB, cor_PNGG, cor_PNGB) |> round(3),
```

```

R2      = c(cor_GBG^2, cor_GBB^2, cor_PNGG^2, cor_PNGB^2) |> round(3)
)

knitr::kable(
  cor_table,
  col.names = c("Groupe", "$r$ (Pearson)", "$R^2$"),
  caption   = "Corrélations de Pearson entre l'âge et la taille par groupe",
  booktabs = TRUE,
  escape    = FALSE
)

```

TABLE 2: Corrélations de Pearson entre l'âge et la taille par groupe

Groupe	r (Pearson)	R^2
GBG (Filles Guinée-Bissau)	0.940	0.883
GBB (Garçons Guinée-Bissau)	0.977	0.955
PNGG (Filles Papouasie N.-G.)	0.940	0.884
PNGB (Garçons Papouasie N.-G.)	0.977	0.955

Ces corrélations sont très élevées, ce qui témoigne d'une forte relation linéaire entre l'âge et la taille. Les garçons présentent des R^2 légèrement plus élevés (0,955 contre 0,883), suggérant que la relation âge-taille est relativement plus régulière pour eux que pour les filles. Néanmoins, un modèle purement linéaire ne capture pas la non-linéarité de la courbe de croissance, en particulier le plateau de croissance observé en fin d'adolescence. Un ajustement polynomial est donc nécessaire.

4 Ajustement polynomial

4.1 Méthode

La régression polynomiale est une généralisation de la régression linéaire simple permettant de capturer des relations non-linéaires entre deux variables. Pour un degré d , le modèle s'écrit :

$$\text{Taille} = \beta_0 + \beta_1 \times \text{Age} + \beta_2 \times \text{Age}^2 + \dots + \beta_d \times \text{Age}^d + \varepsilon$$

Chaque terme polynomial est introduit comme variable explicative supplémentaire dans un modèle de régression linéaire multiple, en conservant la méthode des moindres carrés ordinaires (MCO). Les modèles sont estimés pour des degrés allant de 2 à 7.

Pour sélectionner le degré optimal, nous utilisons le **Critère d'Information d'Akaike (AIC)**. Ce critère pénalise à la fois l'erreur d'ajustement et la complexité du modèle (nombre de paramètres). Un AIC plus faible indique un meilleur compromis qualité/parcimonie. La règle retenue est : on augmente le degré tant que l'AIC diminue ; on s'arrête dès que l'AIC remonte.

4.2 Résultats de la sélection par AIC

4.2.1 Filles – Guinée-Bissau (GBG)

```
x <- GBG$Age
y <- GBG$Taille

poly2_GBG <- lm(y ~ x + I(x^2))
poly3_GBG <- lm(y ~ x + I(x^2) + I(x^3))
poly4_GBG <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4))
poly5_GBG <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4) + I(x^5))
poly6_GBG <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4) + I(x^5) + I(x^6))
poly7_GBG <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4) + I(x^5) + I(x^6) + I(x^7))

aic_GBG <- c(AIC(poly2_GBG), AIC(poly3_GBG), AIC(poly4_GBG),
             AIC(poly5_GBG), AIC(poly6_GBG), AIC(poly7_GBG))
cat("AIC GBG (poly2 à poly7) :", round(aic_GBG, 1), "\n")
```

```
## AIC GBG (poly2 à poly7) : 10496.8 10328.2 10194.5 10162.6 10160.4 10162.4
```

```
cat("Meilleur modèle : poly6 (AIC =", round(AIC(poly6_GBG), 2), ")\n")
```

```
## Meilleur modèle : poly6 (AIC = 10160.39 )
```

4.2.2 Garçons – Guinée-Bissau (GBB)

```
x <- GBB$Age
y <- GBB$Taille

poly2_GBB <- lm(y ~ x + I(x^2))
poly3_GBB <- lm(y ~ x + I(x^2) + I(x^3))
poly4_GBB <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4))
poly5_GBB <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4) + I(x^5))
poly6_GBB <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4) + I(x^5) + I(x^6))
poly7_GBB <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4) + I(x^5) + I(x^6) + I(x^7))
poly8_GBB <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4) + I(x^5) + I(x^6) + I(x^7) + I(x^8))

aic_GBB <- c(AIC(poly2_GBB), AIC(poly3_GBB), AIC(poly4_GBB),
             AIC(poly5_GBB), AIC(poly6_GBB), AIC(poly7_GBB))
cat("AIC GBB (poly2 à poly7) :", round(aic_GBB, 1), "\n")
```

```
## AIC GBB (poly2 à poly7) : 10823.4 10318.8 10266.1 10198.2 10183.5 10182.4
```



```
cat("Meilleur modèle : poly7 (AIC =", round(AIC(poly7_GBB), 2), ")\n")
```

```
## Meilleur modèle : poly7 (AIC = 10182.36 )
```

4.2.3 Filles – Papouasie Nouvelle-Guinée (PNGG)

```
x <- PNGG$Age
y <- PNGG$Taille

poly2_PNGG <- lm(y ~ x + I(x^2))
poly3_PNGG <- lm(y ~ x + I(x^2) + I(x^3))
poly4_PNGG <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4))
poly5_PNGG <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4) + I(x^5))
poly6_PNGG <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4) + I(x^5) + I(x^6))
poly7_PNGG <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4) + I(x^5) + I(x^6) + I(x^7))

aic_PNGG <- c(AIC(poly2_PNGG), AIC(poly3_PNGG), AIC(poly4_PNGG),
              AIC(poly5_PNGG), AIC(poly6_PNGG), AIC(poly7_PNGG))
cat("AIC PNGG (poly2 à poly7) :", round(aic_PNGG, 1), "\n")
```

```
## AIC PNGG (poly2 à poly7) : 10463.6 10317.7 10170.8 10147.7 10137.3 10139.2
```

```
cat("Meilleur modèle : poly6 (AIC =", round(AIC(poly6_PNGG), 2), ")\n")
```

```
## Meilleur modèle : poly6 (AIC = 10137.29 )
```

4.2.4 Garçons – Papouasie Nouvelle-Guinée (PNGB)

```
x <- PNGB$Age
y <- PNGB$Taille

poly2_PNGB <- lm(y ~ x + I(x^2))
poly3_PNGB <- lm(y ~ x + I(x^2) + I(x^3))
poly4_PNGB <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4))
poly5_PNGB <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4) + I(x^5))
poly6_PNGB <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4) + I(x^5) + I(x^6))
poly7_PNGB <- lm(y ~ x + I(x^2) + I(x^3) + I(x^4) + I(x^5) + I(x^6) + I(x^7))

aic_PNGB <- c(AIC(poly2_PNGB), AIC(poly3_PNGB), AIC(poly4_PNGB),
              AIC(poly5_PNGB), AIC(poly6_PNGB), AIC(poly7_PNGB))
cat("AIC PNGB (poly2 à poly7) :", round(aic_PNGB, 1), "\n")
```

```
## AIC PNGB (poly2 à poly7) : 10869 10311.9 10247 10198.7 10194.1 10196.1
```

```
cat("Meilleur modèle : poly6 (AIC =", round(AIC(poly6_PNGB), 2), ")\n")
```

```
## Meilleur modèle : poly6 (AIC = 10194.1 )
```

4.2.5 Tableau récapitulatif des AIC

```
aic_df <- data.frame(
  Modele = paste0("Poly", 2:7),
  GBG    = round(aic_GBG, 1),
  GBB    = round(aic_GBB, 1),
  PNGG    = round(aic_PNGG, 1),
  PNGB    = round(aic_PNGB, 1)
)

knitr::kable(
  aic_df,
  col.names = c("Modèle", "GBG (Filles GB)", "GBB (Garçons GB)",
                "PNGG (Filles PNG)", "PNGB (Garçons PNG)"),
  caption   = "Valeurs d'AIC par degré et par groupe (modèle retenu = AIC minimal)",
  booktabs = TRUE
)
```

TABLE 3: Valeurs d'AIC par degré et par groupe (modèle retenu = AIC minimal)

Modèle	GBG (Filles GB)	GBB (Garçons GB)	PNGG (Filles PNG)	PNGB (Garçons PNG)
Poly2	10496.8	10823.4	10463.6	10869.0
Poly3	10328.2	10318.8	10317.7	10311.9
Poly4	10194.5	10266.1	10170.8	10247.0
Poly5	10162.6	10198.2	10147.7	10198.7
Poly6	10160.4	10183.5	10137.3	10194.1
Poly7	10162.4	10182.4	10139.2	10196.1

Les modèles retenus sont : **Poly6** pour les filles de Guinée-Bissau (AIC = 10 160,4), **Poly7** pour les garçons de Guinée-Bissau (AIC = 10 182,4), **Poly6** pour les filles de Papouasie Nouvelle-Guinée (AIC = 10 137,3), et **Poly6** pour les garçons de Papouasie Nouvelle-Guinée (AIC = 10 194,1). Ces degrés élevés s'expliquent par la complexité de la croissance humaine, qui comporte plusieurs phases distinctes : croissance régulière en enfance, accélération pubertaire, et plateau en fin d'adolescence.

4.3 Courbes d'ajustement polynomiales

```
xseq <- seq(5, 19, by = 0.01)

# Fonction utilitaire pour tracer la courbe polynomiale
plot_poly <- function(groupe_x, groupe_y, meilleur_modele, coefs, degre, titre_plot) {
  model_lm <- lm(groupe_y ~ groupe_x)

  plot(groupe_x, groupe_y,
       pch = ".",
       col = "gray60",
       main = titre_plot,
       xlab = "Âge (années)",
       ylab = "Taille (cm)",
       cex = 1.5)

  # Modèle linéaire (rouge tiret)
  abline(model_lm, col = "red", lwd = 2, lty = 2)

  # Modèle polynomial optimal (bleu foncé)
  y_pred <- coefs[1]
  for (i in 2:length(coefs)) {
    y_pred <- y_pred + coefs[i] * xseq^(i - 1)
  }
  lines(xseq, y_pred, col = "darkblue", lwd = 2)

  legend("topleft",
        legend = c(paste0("Poly", degre, " (meilleur modèle)", "Linéaire"),
                  col = c("darkblue", "red"),
                  lty = c(1, 2),
                  lwd = 2,
                  cex = 0.8)
  )
}

par(mfrow = c(2, 2))

# GBG – Filles Guinée-Bissau (poly6)
plot_poly(GBG$Age, GBG$Taille, poly6_GBG, coef(poly6_GBG), 6,
          "Filles – Guinée-Bissau")

# GBB – Garçons Guinée-Bissau (poly7)
plot_poly(GBB$Age, GBB$Taille, poly7_GBB, coef(poly7_GBB), 7,
          "Garçons – Guinée-Bissau")

# PNGG – Filles PNG (poly6)
plot_poly(PNGG$Age, PNGG$Taille, poly6_PNGG, coef(poly6_PNGG), 6,
          "Filles – Papouasie Nouvelle-Guinée")
```

```
# PNGB – Garçons PNG (poly6)
plot_poly(PNGB$Age, PNGB$Taille, poly6_PNGB, coef(poly6_PNGB), 6,
          "Garçons – Papouasie Nouvelle-Guinée")
```




FIGURE 2 – Ajustement polynomial (meilleur modèle en bleu foncé, linéaire en rouge tiret)

```
par(mfrow = c(1, 1))
```

Les courbes polynomiales captent fidèlement la forme sigmoïde de la croissance humaine. On observe clairement le ralentissement de la croissance en fin d'adolescence, notamment chez les filles dont

la courbe se « tasse » nettement à partir de 14-15 ans, caractérisant l'arrêt de la croissance après la puberté. Chez les garçons, la croissance est plus régulière sur toute la période, avec un léger plateau plus tardif vers 17-18 ans. Le modèle linéaire (en rouge tiret), bien qu'utile comme première approximation, sous-estime la taille en début et en fin de période, et la surestime à l'âge de la puberté.

5 Courbes médianes et quartiles conditionnels

5.1 Méthode

Afin d'obtenir une représentation non paramétrique de la croissance, la plage d'âge (5–19 ans) est divisée en **15 intervalles de longueur égale**. Pour chaque intervalle, on calcule la médiane, le premier quartile (Q1) et le troisième quartile (Q3) des tailles observées. Ces statistiques conditionnelles sont ensuite reliées pour former trois courbes : la courbe médiane (rouge), et les courbes des premier et troisième quartiles (bleu), qui encadrent la moitié centrale des observations.

Cette approche présente l'avantage d'être robuste aux valeurs extrêmes et de ne pas nécessiter d'hypothèses sur la forme de la relation.

5.2 Résultats

```
# Fonction générique pour calculer et tracer les médianes et quartiles conditionnels
courbe_mediane <- function(x, y, titre_plot, m = 15) {
  newx <- cut(x, m)

  firstquant <- function(z) quantile(z, 0.25)
  thirdquant <- function(z) quantile(z, 0.75)

  medcond <- tapply(y, newx, median)
  quantcondun <- tapply(y, newx, firstquant)
  quantcondtrois <- tapply(y, newx, thirdquant)

  xseq1 <- seq(min(x), max(x), by = (max(x) - min(x)) / m)
  xseq11 <- head(xseq1, m)
  xseq12 <- tail(xseq1, m)
  xseq2 <- (xseq11 + xseq12) / 2

  plot(x, y,
    pch = ".",
    col = "gray60",
    main = titre_plot,
    xlab = "Âge (années)",
    ylab = "Taille (cm)",
```

```

    cex = 1.5)

lines(xseq2, c(medcond), col = "red", lwd = 2)
lines(xseq2, c(quantcondun), col = "blue", lwd = 2, lty = 2)
lines(xseq2, c(quantcondtrois), col = "blue", lwd = 2, lty = 2)

legend("topleft",
      legend = c("Médiane", "Q1 et Q3"),
      col = c("red", "blue"),
      lty = c(1, 2),
      lwd = 2,
      cex = 0.8)
}

par(mfrow = c(2, 2))

courbe_mediane(GBG$Age, GBG$Taille, "Filles - Guinée-Bissau")
courbe_mediane(GBB$Age, GBB$Taille, "Garçons - Guinée-Bissau")
courbe_mediane(PNGG$Age, PNGG$Taille, "Filles - Papouasie Nouvelle-Guinée")
courbe_mediane(PNGB$Age, PNGB$Taille, "Garçons - Papouasie Nouvelle-Guinée")

```




FIGURE 3 – Courbes médianes (rouge) et courbes des 1er et 3e quartiles (bleu) par groupe

```
par(mfrow = c(1, 1))
```

Les courbes médianes confirment la dynamique déjà observée avec les ajustements polynomiaux : croissance rapide en enfance (5-12 ans), accélération pubertaire variable selon le sexe, puis ralentissement et plateau. L'écart interquartile (zone entre les courbes bleues) reste relativement stable au fil de l'âge, ce qui indique une variabilité homogène des tailles au sein de chaque groupe d'âge. On ne décèle pas d'élargissement particulier à la puberté, suggérant que les âges de puberté sont assez uniformément distribués dans la population.

6 Comparaisons et conclusions

6.1 Comparaison filles / garçons

```
# Fonction pour tracer la courbe polynomiale optimale
pred_poly <- function(modele, xseq) {
  coefs <- coef(modele)
  y_pred <- coefs[1]
  for (i in 2:length(coefs)) {
    y_pred <- y_pred + coefs[i] * xseq^(i - 1)
  }
  y_pred
}

par(mfrow = c(1, 2))

# --- Guinée-Bissau ---
plot(GBG$Age, GBG$Taille,
     pch = ".", col = "pink", cex = 1.5,
     xlim = c(5, 19), ylim = c(95, 185),
     main = "Comparaison filles/garçons – Guinée-Bissau",
     xlab = "Âge (années)", ylab = "Taille (cm)")
points(GBB$Age, GBB$Taille, pch = ".", col = "lightblue", cex = 1.5)
lines(xseq, pred_poly(poly6_GB, xseq), col = "deeppink", lwd = 2)
lines(xseq, pred_poly(poly7_GBB, xseq), col = "steelblue", lwd = 2)
legend("topleft",
      legend = c("Filles", "Garçons"),
      col = c("deeppink", "steelblue"),
      lwd = 2, cex = 0.8)

# --- Papouasie Nouvelle-Guinée ---
plot(PNGG$Age, PNGG$Taille,
     pch = ".", col = "pink", cex = 1.5,
     xlim = c(5, 19), ylim = c(95, 180),
     main = "Comparaison filles/garçons – Papouasie N.-G.",
     xlab = "Âge (années)", ylab = "Taille (cm)")
points(PNGB$Age, PNGB$Taille, pch = ".", col = "lightblue", cex = 1.5)
lines(xseq, pred_poly(poly6_PNGG, xseq), col = "deeppink", lwd = 2)
lines(xseq, pred_poly(poly6_PNGB, xseq), col = "steelblue", lwd = 2)
legend("topleft",
      legend = c("Filles", "Garçons"),
      col = c("deeppink", "steelblue"),
      lwd = 2, cex = 0.8)
```





FIGURE 4 – Comparaison des courbes de croissance filles/garçons par pays

```
par(mfrow = c(1, 1))
```

Dans les deux pays, on observe un schéma commun caractéristique de la croissance humaine. Les filles croissent plus rapidement que les garçons entre environ 9 et 12 ans (avance pubertaire féminine) : à 10 ans, les filles de Guinée-Bissau mesurent en moyenne 137,0 cm contre 131,6 cm pour les garçons. Cette avance s'inverse progressivement : à 15 ans, les garçons dépassent les filles (GB : 160,8 cm vs 156,6 cm ; PNG : 157,4 cm vs 153,6 cm).

À l'âge adulte (19 ans), les garçons sont nettement plus grands : 167,5 cm vs 159,3 cm en Guinée-Bissau, et 163,6 cm vs 156,3 cm en Papouasie Nouvelle-Guinée. Ces différences sont cohérentes avec la littérature épidémiologique mondiale. Notons également que la variabilité est plus forte chez les garçons (écart-type ≈ 20 cm vs 16 cm), probablement due à une plus grande hétérogénéité des âges de la poussée pubertaire masculine.

6.2 Comparaison des deux pays

```
par(mfrow = c(1, 2))

# --- Filles ---
plot(GBG$Age, GBG$Taille,
     pch = ".", col = "salmon", cex = 1.5,
     xlim = c(5, 19), ylim = c(95, 175),
     main = "Comparaison pays - Filles",
     xlab = "Âge (années)", ylab = "Taille (cm)")
points(PNGG$Age, PNGG$Taille, pch = ".", col = "lightgreen", cex = 1.5)
lines(xseq, pred_poly(poly6_GBG, xseq), col = "red", lwd = 2)
```

```

lines(xseq, pred_poly(poly6_PNGG, xseq), col = "green4", lwd = 2)
legend("topleft",
      legend = c("Guinée-Bissau", "Papouasie N.-G."),
      col      = c("red", "green4"),
      lwd      = 2, cex = 0.8)

# --- Garçons ---
plot(GBB$Age, GBB$Taille,
     pch = ".", col = "salmon", cex = 1.5,
     xlim = c(5, 19), ylim = c(95, 185),
     main = "Comparaison pays – Garçons",
     xlab = "Âge (années)", ylab = "Taille (cm)")
points(PNGB$Age, PNGB$Taille, pch = ".", col = "lightgreen", cex = 1.5)
lines(xseq, pred_poly(poly7_GBB, xseq), col = "red", lwd = 2)
lines(xseq, pred_poly(poly6_PNGB, xseq), col = "green4", lwd = 2)
legend("topleft",
      legend = c("Guinée-Bissau", "Papouasie N.-G."),
      col      = c("red", "green4"),
      lwd      = 2, cex = 0.8)

```




FIGURE 5 – Comparaison des courbes de croissance entre Guinée-Bissau et Papouasie N.-G.

```

par(mfrow = c(1, 1))

```

La Guinée-Bissau présente des tailles légèrement supérieures à celles de la Papouasie Nouvelle-Guinée, pour les deux sexes. Cet écart est modéré mais cohérent : à 15 ans, les filles de GB mesurent 156,6 cm contre 153,6 cm pour les filles de PNG ; les garçons de GB mesurent 160,8 cm contre 157,4 cm pour les garçons de PNG. À 5 ans, les différences sont moins marquées (GB/PNG : 108,2/106,5

cm pour les filles ; 105,5/101,6 cm pour les garçons), indiquant que l'écart tend à se creuser au cours de la croissance.

Ces différences peuvent s'expliquer par plusieurs facteurs : conditions nutritionnelles, accès aux soins, facteurs génétiques et environnementaux propres à chaque région du monde. La Guinée-Bissau et la Papouasie Nouvelle-Guinée sont toutes deux des pays à revenu faible ou intermédiaire, mais leurs profils épidémiologiques et alimentaires diffèrent significativement.

6.3 Tests statistiques Taille ~ Sexe et Pays

```
# Test de Student : taille selon le sexe
```

```
cat("=== Test t : Taille ~ Sexe ===\n")
```

```
## === Test t : Taille ~ Sexe ===
```

```
t.test(Data$Taille ~ Data$Sexe)
```

```
##
```

```
## Welch Two Sample t-test
```

```
##
```

```
## data: Data$Taille by Data$Sexe
```

```
## t = -0.44218, df = 7667.3, p-value = 0.6584
```

```
## alternative hypothesis: true difference in means between group Boys and group Girls is not
```

```
## 95 percent confidence interval:
```

```
## -0.9856595 0.6228330
```

```
## sample estimates:
```

```
## mean in group Boys mean in group Girls
```

```
## 140.7900 140.9714
```

```
# Test de Student : taille selon le pays
```

```
cat("\n=== Test t : Taille ~ Pays ===\n")
```

```
##
```

```
## === Test t : Taille ~ Pays ===
```

```
t.test(Data$Taille ~ Data$Pays)
```

```
##
```

```
## Welch Two Sample t-test
```

```
##
```

```
## data: Data$Taille by Data$Pays
```

```
## t = 7.1451, df = 7998, p-value = 0.0000000000009784
```

```
## alternative hypothesis: true difference in means between group Guinea Bissau and group Papu
```

```
## 95 percent confidence interval:
```

```
## 2.120468 3.723860
## sample estimates:
##      mean in group Guinea Bissau mean in group Papua New Guinea
##                                142.3417                        139.4196
```

Le test Taille~Sexe global n'est pas significatif ($t = -0,442$, $p = 0,658$), les moyennes étant quasi identiques (140,79 cm vs 140,97 cm). Cela ne contredit pas les écarts visibles en Figure 4 : les filles sont plus grandes avant la puberté, les garçons les dépassent ensuite, et ces deux effets opposés s'annulent une fois moyennés sur toute la tranche 5-19 ans. Le test Taille~Pays, en revanche, est hautement significatif ($t = 7,145$, $p < 0,001$) : les enfants de Guinée-Bissau sont en moyenne 2,92 cm plus grands que ceux de Papouasie Nouvelle-Guinée (IC 95 % : [2,12 ; 3,72] cm), confirmant statistiquement l'écart observé en Figure 5.

6.4 Qualité des modèles

Les modèles polynomiaux retenus (degré 6 ou 7) présentent tous de très bons ajustements, confirmés à la fois par des AIC bas et par l'adéquation visuelle aux données. Les courbes polynomiales et les courbes médianes conditionnelles sont en excellent accord, validant mutuellement les deux approches. On notera que l'usage de l'AIC comme critère de sélection a permis d'éviter le sur-ajustement : les modèles de degré 8 ou plus n'apportent pas d'amélioration significative.

7 Conclusion

Cette étude des courbes de croissance en Guinée-Bissau et en Papouasie Nouvelle-Guinée, portant sur 8 000 enfants et adolescents âgés de 5 à 19 ans, permet de dégager plusieurs enseignements importants.

Sur le plan méthodologique, la régression polynomiale (degrés 6 à 7, sélectionnés par AIC) s'avère particulièrement adaptée à la modélisation de la croissance, dont la forme sigmoïde ne peut être capturée par un modèle linéaire simple. L'approche non paramétrique des médianes conditionnelles, robuste et intuitive, constitue un outil complémentaire précieux pour visualiser la dispersion des données.

Sur le plan biologique, les résultats confirment les grandes tendances de la croissance humaine : avance pubertaire des filles entre 9 et 12 ans, rattrapage puis dépassement par les garçons à partir de 13-14 ans, et taille adulte plus élevée chez les garçons. Ces phénomènes sont observés de manière cohérente dans les deux pays, suggérant une universalité des mécanismes biologiques sous-jacents.

Sur le plan comparatif, des différences significatives apparaissent entre les deux pays, avec des enfants de Guinée-Bissau légèrement plus grands que ceux de Papouasie Nouvelle-Guinée. Ces écarts, modérés mais consistants, pourraient refléter des différences dans les conditions nutritionnelles, l'accès aux soins ou les caractéristiques génétiques des populations.

Cette analyse pourrait être enrichie par la prise en compte d'autres variables (niveau socio-économique, milieu rural/urbain, indice de masse corporelle) et par une comparaison à des références internationales telles que les courbes de croissance de l'OMS.

8 Summary

This report investigates height growth curves in children and adolescents aged 5 to 19 years across two countries — Guinea-Bissau (West Africa) and Papua New Guinea (Oceania) — using anthropometric data collected in 2020, with 4,000 observations per country (equally split by sex).

Descriptive statistics reveal comparable mean heights between the two countries, though boys exhibit consistently greater height variability than girls in both populations. Pearson correlations between age and height are high across all groups ($r \approx 0.94$ for girls, $r \approx 0.977$ for boys), confirming a strong and regular age-height relationship.

To account for the non-linear nature of human growth, polynomial regression models of degrees 6 to 7 were fitted and selected via AIC minimization. The resulting curves accurately capture the characteristic sigmoidal growth pattern — rapid gain in childhood, pubertal acceleration, and a plateau in late adolescence. In Guinea-Bissau, the optimal model is degree 6 for girls (AIC = 10,160.4) and degree 7 for boys (AIC = 10,182.4); in Papua New Guinea, degree-6 polynomials were selected for both sexes.

As a complementary non-parametric approach, conditional median and quartile curves were computed over 15 equal-width age intervals, corroborating the polynomial fits and providing an assumption-free visualization of growth dispersion.

Three key findings emerge from the analysis: girls grow faster than boys between ages 9 and 12 due to earlier puberty onset, but boys surpass girls in height from around age 13–14 onward; children in Guinea-Bissau are slightly but consistently taller than their Papua New Guinean counterparts at comparable ages; and height variability is systematically greater in boys, likely driven by greater heterogeneity in the timing of male pubertal growth spurts.

These findings align with established patterns in global pediatric epidemiology and underscore the value of polynomial modeling for capturing the complexity of human growth data.